

**Akademia Górniczo-Hutnicza im Stanisława
Staszica Wydział Automatyki, Elektroniki
Informatyki i Inżynierii Biomedycznej**



AUTOMATYCZNA SEGMENTACJA NEREK

**PROJEKT REALIZOWANY W RAMACH PRZEDMIOTU
TECHNIKI OBRAZOWANIA MEDYCZNEGO**

Alicja Kojs

Anastazja Kąkol

Wojciech Rolka

Kraków, 16.06.2020

Spis treści

Abstrakt.....	3
2. Wprowadzenie	4
2. Cel projektu	4
3. Przegląd literaturowy	4
4. Wykorzystane metody	6
4.1 Postępowanie	7
5. Prezentacja wyników	7
6. Podsumowanie.....	10
7. Bibliografia	11
8. Podział pracy	11
9. Załączniki	11

Abstrakt

Idea projektu zrodziła się na konferencji naukowej MICCAI 2019, podczas której rzucono wyzwanie, które pozwoli na automatyczną segmentację nerek i nowotworów nerek w obrazach tomografii komputerowej. Jest to problem, którego rozwiązanie znacznie usprawni proces analizy. W projekcie znajduje się informacja na temat wcześniejszych dokonań związanych z segmentacją. Przedstawione zostały metody, których naukowcy już wcześniej używali, aby wyodrębnić interesujący ich fragment narządu, bądź cały narząd. Omówiony zostanie algorytm, który można wykorzystać w przypadku modelu 3D obrazu, oceny funkcji określonego narządu poprzez zastosowane badania pilotażowe oraz ogólne zastosowanie algorytmu segmentacji. W kolejnej części znajduje się informacja o wykorzystanych przez nas metodach analizy obrazu. Na końcu zestawiono otrzymane obrazy dla sześciu przekrojów z widocznymi nerkami, na których zastosowano algorytm aktywnego konturu.

1. Wprowadzenie

Co roku pojawia się ponad 400 tysięcy nowych przypadków wystąpienia nowotworu nerek u ludzi. Najpopularniejszym rozwiązaniem jest zabieg chirurgiczny, który pozwala na częściowe lub całościowe usunięcie powstałych komórek nowotworowych. Nowotwory ze względu na swój proces tworzenia może mieć różne kształty i objętości. Współcześni naukowcy dążą do opracowania metody, która pozwoli na automatyczną detekcję zmian w obrębie narządu. W tym projekcie staramy się odpowiedzieć na wyzwanie przez nich rzucone, aby zautomatyzować proces detekcji narządów i ich nowotworów, na przykładzie nerki.

2. Cel projektu

Celem projektu jest poznanie metody segmentacji poprzez zaznajomienie się z dostępną literaturą oraz zrobienie krótkiego przeglądu literaturowego. Projekt w głównej mierze polega na zaimplementowaniu algorytmu, który pozwoli na automatyczną segmentację nerek oraz ich nowotworów za pomocą metody aktywnych konturów. Ważną częścią jest ocena uzyskanych wyników, ich poprawności i automatyczności.

3. Przegląd literaturowy

Techniki analizy obrazów pozwalają na wyznaczenie obiektywnych parametrów oceny funkcjonowania narządu. W przypadku analizy serii zdjęć wykonanych za pomocą tomografii komputerowej możliwa jest dokładna analiza każdego otrzymanego przekroju.

W artykule [1] przeprowadzano segmentację obrazów medycznych 3D narządów wewnętrznych człowieka, poprzez połączenie wykonywanych szeregowo znanych algorytmów wstępnego przetwarzania. W badaniu przeprowadzonym przez naukowców zastosowano nowatorską metodę, która polega na odpowiednim doborze algorytmów przetwarzania, ich właściwej kolejności oraz stosownych parametrów. Algorytm segmentacji wykorzystano na danych, uzyskanych za pomocą rezonansu magnetycznego oraz tomografu komputerowego. Obrazy były zapisane w formacie DICOM, w postaci przekrojów. Zastosowane zostały biblioteki dla języka Python, takie jak VTK (*Visualisation Toolkit*) oraz SimpleITK. Dodatkowo zastosowano program *3D Slicer*, który umożliwił stworzenie wizualizacji 3D wyodrębnionych segmentów organizmu. Jednakże, ta opcja nie była wystarczająco dobra do wykorzystania w medycynie, dlatego zastosowano algorytm indeksacji obrazów metodą rozrostu. Dzięki temu wydzielono jednolity obszar dla danego narządu. Zaimplementowany algorytm rozrostu, działający na obrazie binarnym polega na indeksacji od określonego punktu, następnie przeglądane jest sąsiedztwo tego punktu wypełniając je numerem indeksu. Takie punkty dodaje się do wirtualnego stosu i przetwarza w pętli, aby zapobiec jego wyczerpaniu. Oryginalny algorytm opracowany przez naukowców polegał na użyciu progowania, operatorów morfologicznych, takich jak erozja i dylatacja oraz indeksacji metodą rozrostu. Dodatkowo, użyto większy element strukturalny do operacji dylatacji, co wpłynęło na wydłużenie połączeń między innymi obiektami. Przeprowadzone porównanie nowatorskiej metody z metodą, która nie uwzględnia filtracji i morfologii wykazało, że

zastosowanie tych dwóch operacji znacznie wpływa na jakość wydzielonego obrazu. W przypadku obrazów, w których nie zastosowano operacji filtracji i morfologii, nie było możliwe wydzielenie odrębnych narządów.

W artykule [2], w jednym z podrozdziałów - „Automatyczne rozpoznawanie obrazów medycznych” - autor mówi o angażowaniu komputerów nie tylko do prezentacji ale i automatycznej interpretacji obrazów medycznych. We wcześniejszych podrozdziałach wyjaśniono, czym jest obraz i jego cyfrowa prezentacja, jakie są komputerowe metody obrazowania medycznego oraz w jaki sposób i po co obróbce poddaje się obrazy rentgenowskie. Nowoczesne rozwiązania mają pozwolić na automatyczne wykrywanie patologii (zmian patologicznych) narządów. Zastosowanie komputerów do interpretacji obrazów może pozwolić na dokładniejszą analizę – komputer może „wychwycić” to, czego nie zauważy lekarz patrząc na obraz, co jest związane z ograniczeniami ludzi np. w kwestii liczby rozróżnialnych odcieni szarości. Narząd stanowi model, który za pomocą metod grafiki komputerowej jest wizualizowany, a następnie dokładnie analizowany. Analiza możliwa jest dzięki obróbce obrazu i zwiększeniu jego czytelności.

W kolejny artykule [3] opisano wprowadzenie nowych metod, pozwalających na zobrazowanie głośni podczas fonacji i wyznaczenie parametrów oceny drgań fałdów głosowych. Metody te mają pozwolić lekarzom na lepszą diagnostykę narządu głosu - głośni. Ogólna idea polegała na wykonaniu badań wideostroboskopowych głośni u 15 badanych, z czego 5 z nich miało guzki głosowe, 5 – niedomykalność głośni i 5 – prawidłową budowę głośni. Na początku nagrano filmy przy użyciu techniki wideostroboskopowej za pomocą specjalnego urządzenia – wideostroboskopu. Następnie wybrane zostały zarejestrowane sekwencje, pochodzące od wyżej wymienionych 15 osób, do analizy. Opracowane zostały algorytmy pozwalające na przetwarzanie, segmentację i analizę obrazów głośni, co z kolei miało pozwolić na automatyczną parametryzację światła głośni w czasie fonacji. Algorytmy zaimplementowane zostały w postaci programów w językach Python, C++ z wykorzystaniem biblioteki funkcji analizy obrazów – OpenCV. Na początku istotne było wstępne przetwarzanie

pierwszego obrazu, poprzez jego filtrację cyfrową (redukcja zakłóceń) i wyrównanie kontrastu poprzez modelowanie histogramu obrazu, a następnie wyznaczenie obszaru zainteresowania, poprzez segmentację wododziałową (podział obrazu gradientowego według kryterium jasności) – kroki te miały pozwolić na poprawę jakości obrazu. Kolejnym krokiem było zastosowanie procedury przemieszczenia cyfrowego obszarów głośni w każdym kolejnym obrazie sekwencji wideo do położenia w pierwszym obrazie – pozwoliło to na uzyskanie filmu o stałym położeniu głośni w kadrze obrazu. Taki krok pozwolił na precyzyjniejszą obserwację ruchu badanego narządu. Następnie zaimplementowano algorytm, pozwalający na wyznaczenie konturu światła głośni, dzięki metodzie Otsu – kryterium segmentacji stanowi informacja o rozkładzie statystycznym jakości punktów w obszarze zainteresowania. Obliczone zostały także podstawowe parametry geometryczne narządu. Na podstawie uzyskanych wyników wykreślono sygnały pola głośni oraz wyznaczono glottowibrogramy, co pozwalana odwzorowanie kinematyki fałdów głosowych podczas fonacji. W ostatnim badanym przez nas źródle [4] autor między innymi opisuje użycie sieci oscylatorów w celu wykrywania krawędzi obiektów lub granic obszarów. Aby móc to osiągnąć, definiowane są wagi sieci, które zależą od wartości cech j -tego piksela obrazu i cech wyznaczonych w sąsiedztwie punktu i .

Na podstawie ich aktywności możliwe jest wyznaczenie granic między obszarami w jednorodnym obrazie, bądź też między obiektem a tłem. W przypadku obiektów określonych, które są reprezentowane przez oscylatory, oscylatory te są zsynchronizowane, a w przypadku, kiedy obiekty są różne, bądź mamy do czynienia z tłem obrazu – oscylatory są zdesynchronizowane. Równania różniczkowe rozwiązywane są metodą Rungego-Kutty. Można ich także uniknąć, stosując uproszczoną metodę, polegającą na analizie przemieszczenia odpowiedzi oscylatora w przestrzeni fazowej. Przejście oscylatora z lokalnego minimum do prawej gałęzi i lokalnego maksimum do lewej gałęzi ma miejsce w tym samym czasie, dzięki czemu układ równań jest znacznie uproszczony i możliwe jest rozwiązanie problemu w sposób analityczny.

W dalszej części autor opisuje między innymi monitor udaru, który wykorzystuje bezkontrastowe badania CT mózgu do diagnozy zmian niedokrwiennych. Algorytm MU bazuje na etapach, takich jak segmentacja obrazu, ekstrakcja cech hipodensyjnych oraz wizualizacji obszarów badanych z poprawą kontrastu. Segmentacja możliwa jest poprzez wykorzystanie wstępnej ekstrakcji mózgowia, które zostało wydzielone z tła i części kostnych, poprzez zastosowanie skojarzonych metod rozrostu regionów, adaptacyjnego progowania, a także modelowania histogramów z wykorzystaniem tzw. „mieszaniny Gaussów”. Następnie, segmentacji uległy widoczne przestrzenie wypełnione płynem mózgowo-rdzeniowym, w celu uwidocznienia naturalnych komór, bruzd, czy obecnych już, starych blizn pourazowych. Możliwe jest to, dzięki zastosowaniu metod progowych rozrostu wyznaczanych i korygowanych centrów niedokrwienia. Artefakty i obszary nieistotne diagnostycznie są również segmentowane – manualnie ze wspomaganie rysowania, co pozwala na lepsze ustalenie obszarów podatnych na dane schorzenie oraz korektę spójności obszarów i gładkości krawędzi. Kolejnym etapem jest ekstrakcja cech hipodensyjnych w obszarach występowania zmian, którą osiąga się przez dekonpozycję wielkoskalową, adaptacyjne odszumienie i podkreślenie sygnału z modyfikacją rozkładu współczynników, rekonstrukcję obszarów integrowanych z sąsiadującym obszarem mózgowia i dwustopniowe przetwarzanie wielkoskalowe. Na końcu konieczna jest wizualizacja obszarów z poprawą kontrastu, które są możliwe poprzez wyrównanie histogramu, dodatkowe skontrastowanie obszarów objętych udarem, a także nałożenie na siebie poszczególnych obszarów w obrazie wynikowym.

4. Wykorzystane metody

Metoda wykorzystana w projekcie opierała się na wysegmentowaniu z obrazów uzyskanych za pomocą tomografii komputerowej nerek. W celu ujednolicenia działania algorytmu, wszystkie wykorzystane przekroje były konwertowane na skalę szarości. Następnie wycięto te fragmenty, w których nie było obecnych nerek. Tak uzyskane obrazy poddano dalszej analizie. Najpierw poddano je działaniu filtra uśredniającego, który miał za zadanie pozbycie się szumów obrazu. Jego działanie polega na usunięciu szumów, a uśrednia wartość piksela z wartościami ośmiu otaczających pikseli, pod warunkiem, że są one bardzo podobne do wybranego piksela. Do tak przygotowanego obrazu wyznacza się krawędzie przy pomocy funkcji Canny’ego. Wartości progowe były wyznaczane dla każdego przypadku osobno. Funkcja, która wykorzystuje algorytm Canny’ego polega na wielostopniowej filtracji przy pomocy pochodnej Gaussa, która oblicza intensywność gradientów. Wykorzystanie modelu aktywnego konturu pozwala na dopasowanie wartości do linii czy krawędzi na obrazie poprzez

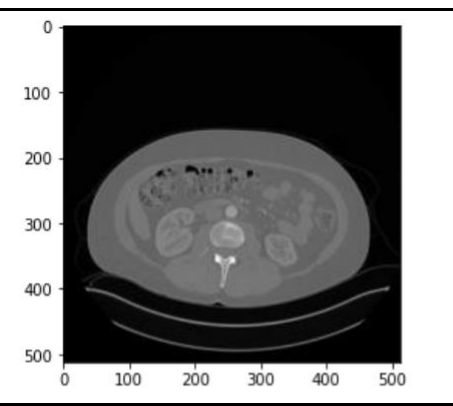
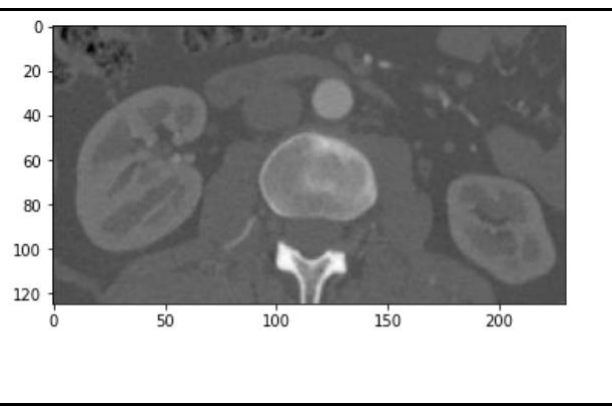
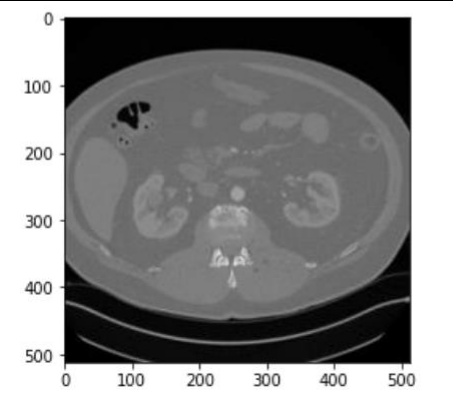
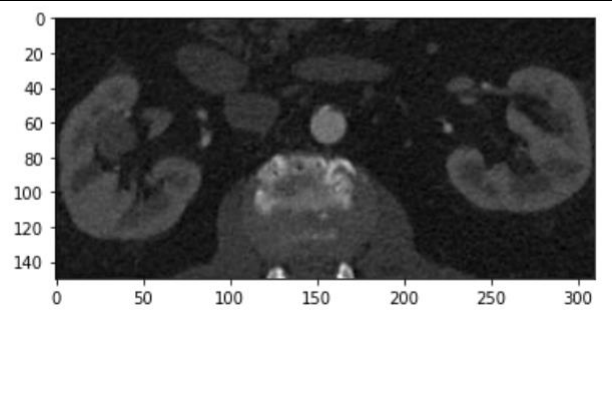
zminimalizowanie energii, która jest określona w części przez sam kształt sklejaną (długość i gładkość), a w części przez sam obraz. Taki aktywny kontur dopasowuje się automatycznie do segmentowanej tkanki, wykreślając jej zarys. Na obrazie pojawia się jako kolorowy kontur, naniesiony na obraz pierwotny.

4.1. Postępowanie

Pierwszym, najważniejszym krokiem, jest wczytanie danych do programu. Analiza obrazów będących w zapisie w formacie *.nii* niezbędne jest z użyciem biblioteki *nibabel*, umożliwiającej pracę na takim formacie. W kolejnym kroku należy wyodrębnić przekroje, które zawierały widoczne nerki. Tak wczytany obraz powinno się przyciąć jak macierz, dzięki czemu tylko interesujący nas obszar będzie poddany segmentacji. W kolejnym kroku wyodrębniony fragment poddaje się filtracji uśredniającej i odszumiającej. Do takiego obrazu należy dobrać odpowiednie wartości σ i τ , które są częścią detekcji krawędzi Canny'ego. Ostatnim krokiem jest poddanie obrazu działaniu, które wykryje krawędzie i naniesie je na obraz wejściowy. Tak uzyskany kontur można zwizualizować za pomocą funkcji *plt.show()*.

5. Uzyskane wyniki

Tabela 1. Zestawienie wybranych przekrojów

Wyodrębniony przekrój	Przycięty przekrój
	
	

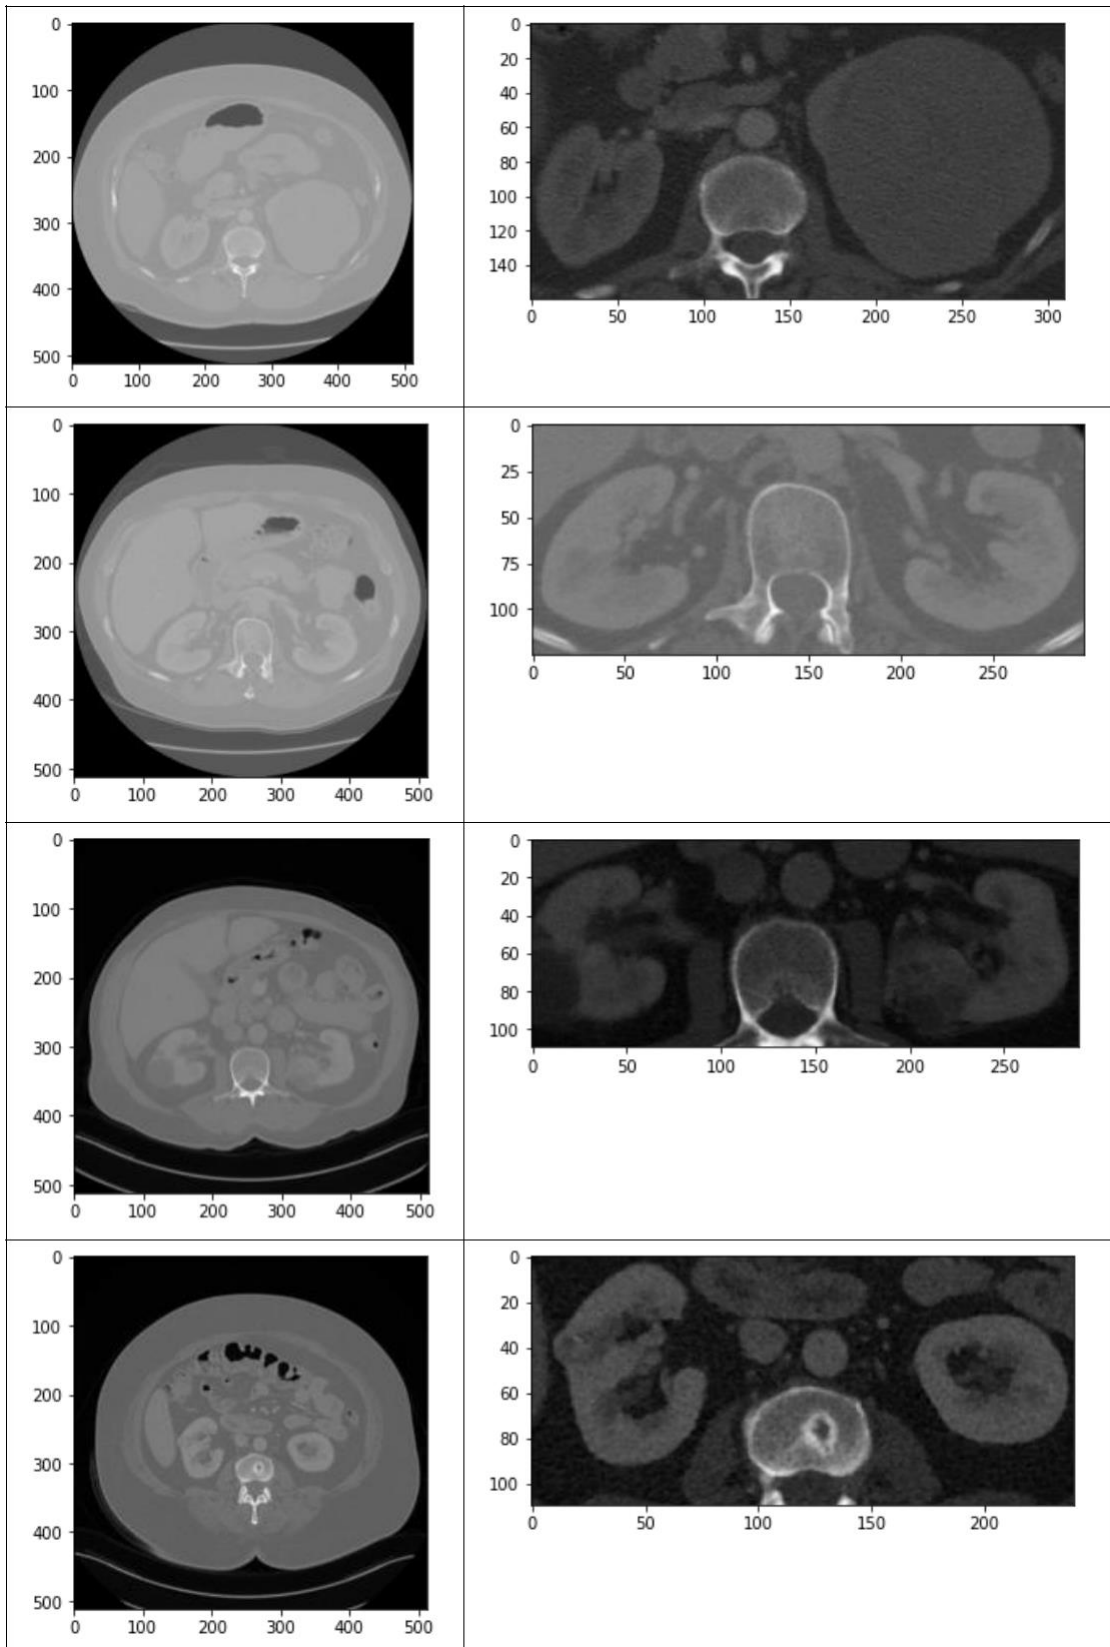
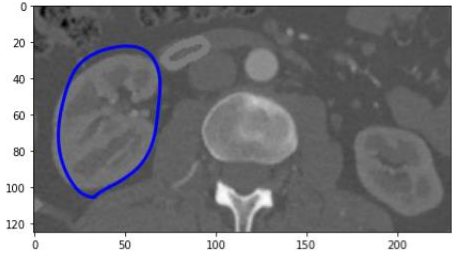
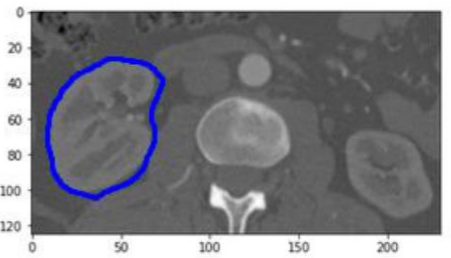
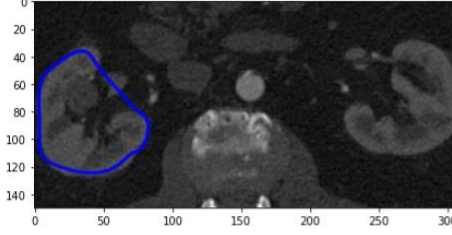
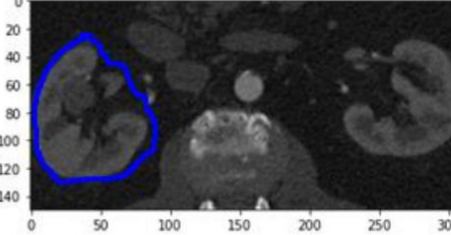
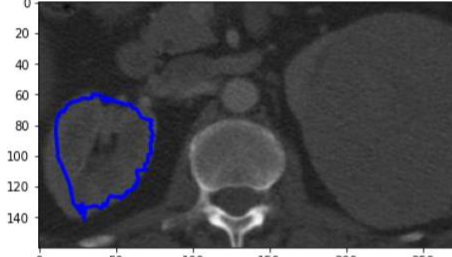
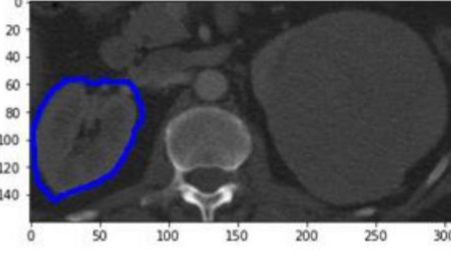
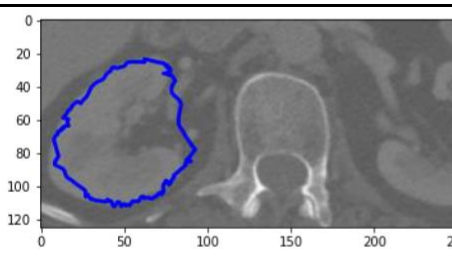
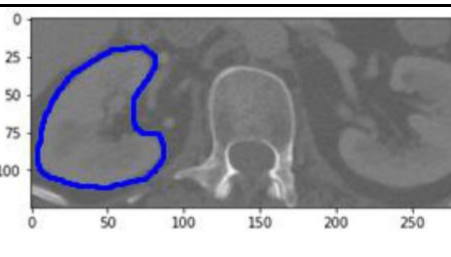
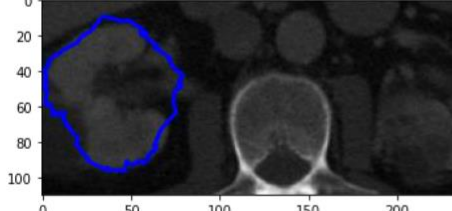
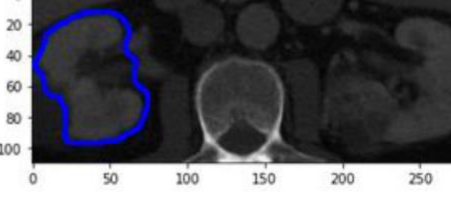
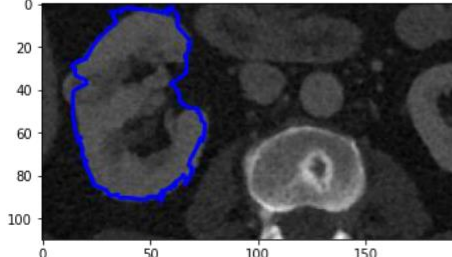
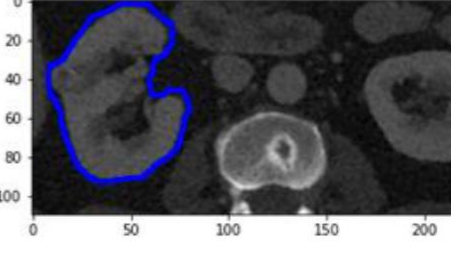


Tabela 2. Zestawienie obrazów z uzyskanymi konturami

Obraz po zastosowaniu metody aktywnych konturów	Obraz po zastosowaniu ręcznej segmentacji
 <p>CT scan slice showing a kidney with a blue active contour. The y-axis ranges from 0 to 120, and the x-axis ranges from 0 to 200.</p>	 <p>CT scan slice showing a kidney with a blue manual segmentation contour. The y-axis ranges from 0 to 120, and the x-axis ranges from 0 to 200.</p>
 <p>CT scan slice showing a kidney with a blue active contour. The y-axis ranges from 0 to 140, and the x-axis ranges from 0 to 300.</p>	 <p>CT scan slice showing a kidney with a blue manual segmentation contour. The y-axis ranges from 0 to 140, and the x-axis ranges from 0 to 300.</p>
 <p>CT scan slice showing a kidney with a blue active contour. The y-axis ranges from 0 to 140, and the x-axis ranges from 0 to 300.</p>	 <p>CT scan slice showing a kidney with a blue manual segmentation contour. The y-axis ranges from 0 to 140, and the x-axis ranges from 0 to 300.</p>
 <p>CT scan slice showing a kidney with a blue active contour. The y-axis ranges from 0 to 120, and the x-axis ranges from 0 to 250.</p>	 <p>CT scan slice showing a kidney with a blue manual segmentation contour. The y-axis ranges from 0 to 100, and the x-axis ranges from 0 to 250.</p>
 <p>CT scan slice showing a kidney with a blue active contour. The y-axis ranges from 0 to 100, and the x-axis ranges from 0 to 250.</p>	 <p>CT scan slice showing a kidney with a blue manual segmentation contour. The y-axis ranges from 0 to 100, and the x-axis ranges from 0 to 250.</p>
 <p>CT scan slice showing a kidney with a blue active contour. The y-axis ranges from 0 to 100, and the x-axis ranges from 0 to 200.</p>	 <p>CT scan slice showing a kidney with a blue manual segmentation contour. The y-axis ranges from 0 to 100, and the x-axis ranges from 0 to 200.</p>

6. Podsumowanie

Analizie poddano sześć przekrojów, na których dobrze widoczne były nerki. W celu zautomatyzowania procesu obrazu zostały przekształcone na skale szarości, co umożliwia ich późniejszą obróbkę. Przycięcie obrazów pozwoliło na eliminację innych widocznych narządów, co znacznie usprawniło proces wykrywania krawędzi. Zaimplementowany przez nas algorytm wykrywa krawędzie, jednak nie jest to bardzo dokładna metoda. Dużo lepsze wyniki zostały uzyskane podczas ręcznej segmentacji, podczas której obrys był bardziej zaokrąglony i odległość między nim a krawędzią narządu znacznie mniejsza. W przypadku konturu uzyskanego za pomocą automatycznej segmentacji, obrys odbiegał od rzeczywistego, pojawiały się nierówności i załamania. W niektórych przypadkach obrys był znacznie mniejszy niż przewidywane kontury, a niekiedy znacznie większy. Obrisy uzyskane za pomocą segmentacji ręcznej były nieznacznie większe, ale można je uznać za poprawne.

Metoda automatycznej segmentacji nerek może być wykorzystywana w przypadku analizy zaawansowanych obrazów wykonanych przy pomocy tomografii komputerowej. W literaturze zastosowano nowoczesne algorytmy, które doskonale spełniają swoje zadanie. Algorytm segmentacji miał za zadanie wyznaczenie krawędzi nerki w obrazach medycznych. Zaproponowana przez nas metoda automatycznej segmentacji wyznacza kontury interesującego nas narządu. Uzyskane kontury metodą automatyczną nie odwzorowują idealnie konturu przedstawionego na obrazie. Znacznie lepszy efekt uzyskano za pomocą segmentacji ręcznej. Segmentacja automatyczna ma wielki potencjał. Aby efekt był zadowalający i powtarzalny, należałoby lepiej dobrać parametry, które dobraliśmy. Tego typu algorytmy, które mają pozwalać na automatyczną segmentację narządów i nowotworów mogą znacząco poprawić i ułatwić lekarzom diagnostykę, a tym samym przyczynić się do uratowania wielu osób.

7. Bibliografia

- [1] “Algorytm segmentacji obrazów medycznych 3D przy wykorzystaniu operatorów morfologicznych oraz indeksacji metodą rozrostu”, Łukasz Maciura, Konrad Wojciechowski, Przegląd elektrotechniczny, ISSN 0033-2097, R. 91 NR 5/2015
- [2] “Podstawy algorytmiki. Zastosowania informatyki Zbiór wykładów Wszechnicy Popołudniowej”, prof. dr hab. Maciej M. Sysło, Magdalena Kopacz , Warszawa 2011
- [3] “Ocena funkcji fonacyjnej krtani z zastosowaniem komputerowej analizy obrazów laryngowideostroboskopowych – badania pilotażowe”, Bartosz Kopczyński, Paweł Strumiłło, Ewa Niebudek-Bogusz, Łódź 2014
- [4] “Neurocybernetyka teoretyczna”, Ryszard Tadeusiewicz, Warszawa 2009

8. Podział pracy

Anastazja Kąkol – przegląd literaturowy, segmentacja ręczna

Alicja Kojs- wstęp, cel ćwiczenia, opis metody, segmentacja automatyczna

Wojciech Rolka – abstrakt, podsumowanie, pomoc przy segmentacji automatycznej i ręcznej

9. Załączniki

Plik z kodem źródłowym zawierający algorytm segmentacji.